

SrcMarker: Dual-Channel Source Code Watermarking via Scalable Code Transformations

背景

- 开源社区的扩展和大型语言模型的兴起引发了对源代码分发的道德和安全问题，例如对受版权保护的代码的不当行为、在没有适当许可的情况下分发或将代码滥用于恶意目的。因此，跟踪源代码的所有权很重要，其中水印是一项主要技术。
- 但几乎没有用于为源代码添加水印的解决方案。源代码与其他内容的不同之处在于它包含两个信息渠道：自然和正式。开发人员使用自然通道进行理解，而编译器等工具使用正式通道进行自动处理。这种内在特征决定了代码本质上是复杂和微妙的。传统的软件水印技术通常对编译好的程序二进制文件进行操作，因此程序可读性差；而文本水印方法也存在不足，因为它们通常依赖于单词替换或句子释义，这会引入不受限制的更改，应用在代码中有可能破坏代码语法。

挑战

- 代码的自然性高度依赖于上下文，要求系统考虑上下文信息。因此，基于规则的方法受到限制，因为它们很少考虑上下文，并且倾向于产生固定或同质的模式。
- 正式通道上有严格的语法规则。对代码的修改必须严格遵循其语法，否则修改后的代码将在语法上无效或语义上不正确。
- 最为关键的：源代码及其转换都是离散且不可微分的，这与基于学习的设计本质上不一致。虽然现有的源代码工作利用了启发式或随机搜索来“绕过”这种离散性，但这些方法不能用于从头开始训练模型，因为训练过程不可避免地需要梯度信息

模型设计方案





Figure 2. The architecture of SrcMarker. Note that the two “Code Encoder” blocks (in embedding and extraction modules respectively) refer to the same neural network, and the same applies to the two “Watermark Decoder” blocks (in extraction and approximation modules).

- 模型分为水印嵌入、水印提取、特征近似三个模块。水印嵌入模块需要训练代码编码器、水印编码器、变换选择器，水印提取模块需要训练水印解码器、代码编码器用的是水印嵌入模块的，特征近似模块需要训练近似编码器、水印解码器用的是水印解码模块的。

水印嵌入模块




- 此模块将水印位串通过代码变换和变量替换嵌入源代码，同时保证代码语义和可读性。上面我们提到过代码分为两个信息渠道，自然和正式。自然是程序员面对的部分，这部分主要体现在变量名这种感官上的部分。正式是编译器面对的部分，这部分重点是程序能否顺利且相同的执行。自然层面就是改变量名，正式层面是代码结构上for与while的相互替换。

水印提取模块

- 此模块目标是输入嵌入模块得到的代码，输出正确的水印。

特征近似模块



- 此模块是最重要的模块，它对one-hot向量使用Gumbel-Softmax 采样，使得其可以在训练中进行反向传播。
- 这个模块有两个训练方向，优化模型替换策略的选择和逼近真实的水印提取特征。
- 如图，输入为源代码特征向量以及两个概率的Gumbel采样，近似编码器得到近似特征向量。而具体的优化选择策略通过掩码的方式进行，模型先得出不可能的选择，再随机屏蔽50%的选择，最后从剩余的选择中进行选择，以期望模型能够探索更多的选择。

Figure 4. Network architecture of the feature approximator with probabilistic masking mechanism.